


Due spazi reali \mathbb{R}^n

$$\begin{matrix} x \\ y \end{matrix} \in \mathbb{R}^n$$

$$\cos \theta = \frac{\langle x, y \rangle}{\|x\| \|y\|} = \frac{x^T y}{\|x\| \|y\|}$$



Linear Correlation (similitudine del coseno)

Supponiamo di aver condotto un esperimento e che le osservazioni siano state raccolte in due settori

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

Indichiamo con $\mathbb{1} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^n$

Problema Determinare l'esistenza di una relazione lineare di x e y ovvero determinare con quale grado le componenti di y sono correlate (linearmente) con quelle di x .
Cioè vogliamo determinare (misurare) quanto y è vicino a una combinazione lineare di x ovvero se possiamo scrivere

$$y = \beta_0 \mathbb{1} + \beta_1 x \quad \text{per qualche } \beta_0 \text{ e } \beta_1$$

Soluzione Il caso dell'esempio formato da x e y ci fornisce il grado di correlazione lineare tra questi setto.
Per dimostrare questa affermazione consideriamo

$$\mu_x = \frac{\sum_i x_i}{n} = \frac{\mathbb{1}^T x}{n} \quad \text{media (tendenza principale dei dati)}$$

$$\sigma_x = \sqrt{\frac{\sum (x_i - \mu_x)^2}{n}} = \frac{\|x - \mu_x \mathbb{1}\|_2}{\sqrt{n}}$$

deviazione standard
misura il grado con cui i dati sono sparpagliati

È frequente nelle applicazioni trovarsi di fronte a dati che sono stati calcolati con diverse unità di misura. Per tanto tali dati potrebbero essere difficilmente comparabili. Si procede quindi ad effettuare la cosiddetta "standardizzazione" in quantità indipendenti dall'unità di misura.

(29)

DEF. La standardizzazione di un vettore $x \in \mathbb{R}^n$ $\sigma_x \neq 0$ è data da
$$Z_x = \frac{x - \mu_x \mathbb{1}}{\sigma_x}$$

Le componenti del vettore Z_x si dicono z-scores (o punteggi standard).

I vettori standardizzati sono tali che $\|Z\| = \sqrt{n}$ $\mu_Z = 0$ $\sigma_Z = 1$

Si verifica che:

$x, y \in \mathbb{R}^n$ e' $\sigma_x \neq 0$ e $\sigma_y \neq 0$

$$Z_x = Z_y \iff \exists \beta_0, \beta_1 \ni y = \beta_0 \mathbb{1} + \beta_1 x \quad \beta_1 > 0$$

$$Z_x = -Z_y \iff \exists \beta_0, \beta_1 \ni y = \beta_0 \mathbb{1} + \beta_1 x \quad \beta_1 < 0$$

In altre parole $y = \beta_0 \mathbb{1} + \beta_1 x$ per qualche β_0 e $\beta_1 \iff Z_x = \pm Z_y$ (e diremo che y è perfettamente correlato con x)

Poiché Z_x dipende da x , Z_x sarà tanto più vicino a $\pm Z_y$ quanto più x è linearmente correlato a y .

Osserviamo che $\|Z_x\| = \sqrt{n} = \|\pm Z_y\| \Rightarrow Z_x$ e $\pm Z_y$ differiscono solo nell'orientazione quindi una misura naturale per valutare quanto Z_x sia vicino a $\pm Z_y$ è data dal $\cos \vartheta$

$$\begin{aligned} \rho_{xy} = \cos \vartheta &= \frac{Z_x^T Z_y}{\|Z_x\| \|Z_y\|} = \frac{Z_x^T Z_y}{n} = \frac{(x - \mu_x \mathbb{1})^T (y - \mu_y \mathbb{1})}{n \sigma_x \sigma_y} \\ &= \frac{(x - \mu_x \mathbb{1})^T (y - \mu_y \mathbb{1})}{\|x - \mu_x \mathbb{1}\|_2 \|y - \mu_y \mathbb{1}\|_2} \end{aligned}$$

ρ_{xy} è detto coefficiente di correlazione lineare

29 bis

$\rho_{xy} = 0 \quad x \perp y \Rightarrow x, y$ sono completamente scorrelati

$|\rho_{xy}| = 1 \Leftrightarrow y$ è perfettamente correlato a x


y positivamente correlato a $x \quad x \quad \beta_1 > 0$

y negativamente correlato a $x \quad \beta_1 < 0$

$|\rho_{xy}|$ misura il grado con cui y è lin. ^{legato} ~~correlato~~ a x


$\rho_{xy} \approx 1$ correlaz. positiva

osservo i dati appartengono ad una retta con inclinazione positiva




$\rho_{xy} \approx -1$ correlaz. negativa

\Rightarrow i dati giacciono su una retta con inclinazione negativa



$\rho_{xy} \approx 0$

nessuna correlazione



Decomposizione a valori singolari

Sia $A \in \mathbb{C}^{m \times n}$ $\text{rank}(A) = p = \min(m, n)$, allora $\exists U, \Sigma, V$
 $U \in \mathbb{C}^{m \times m}$ unitaria ($U^H U = I_m = U U^H$)
 $V \in \mathbb{C}^{n \times n}$ unitaria ($V^H V = I_n = V V^H$)
 Σ matrice diagonale a blocchi $\Sigma \in \mathbb{R}^{m \times n}$ $\Sigma = \begin{pmatrix} D & 0 \\ 0 & 0 \end{pmatrix}$
 $D \in \mathbb{R}^{p \times p}$ $D = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$ con $\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \dots \geq \sigma_p > 0$
 $p \leq \min(m, n)$ σ_i sono detti valori singolari di A
 $A = U \Sigma V^H$ dec. a valori singolari (SVD) di A
 $U = [u_1 | u_2 | \dots | u_m]$ u_i si dicono vettori singolari sinistri
 $V = [v_1 | v_2 | \dots | v_n]$ v_i " " " " destri

Si osserva che dalla relazione

$$A = U \Sigma V^H = \sum_{i=1}^r \sigma_i u_i v_i^H$$

v_1, \dots, v_r basi ortogonali per $\text{col}(A)$
 u_1, \dots, u_r basi ortogonali per $\text{row}(A)$
 v_{r+1}, \dots, v_n basi ortogonali per $\text{col}(A)^\perp$
 u_{r+1}, \dots, u_m basi ortogonali per $\text{row}(A)^\perp$
 $r = \text{rank}(A)$

inoltre da

$$AV = U \Sigma \Rightarrow A v_i = \sigma_i u_i \quad i=1, \dots, r$$

$$A^H = V \Sigma^H U^H \Rightarrow A^H U = V \Sigma^H \Rightarrow A^H u_i = \sigma_i v_i \quad i=1, \dots, r$$

Teorema Sia $A \in \mathbb{C}^{m \times n}$ e sia $A = U \Sigma V^H$ la SVD di A

t.c. $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > \sigma_{k+1} = \dots = \sigma_p = 0$ ($\text{rank}(A) = k$)

Allora si ha che

$$1) A = U_k \Sigma_k V_k^H = \sum_{i=1}^k \sigma_i u_i v_i^H \quad \text{dove}$$

$$U_k \in \mathbb{C}^{m \times k}$$

\bar{u} la matrice $U = [u_1 | u_2 | \dots | u_k]$ dei primi k vettori singolari sinistri

$$V_k \in \mathbb{C}^{k \times n}$$

\bar{v} la matrice $V = [v_1 | v_2 | \dots | v_k]$ le cui colonne sono i primi k sett. sing. destri

$\Sigma_k \in \mathbb{R}^{k \times k}$ è la matrice diagonale i cui elementi diagonali sono $\sigma_1, \sigma_2, \dots, \sigma_k$

Infatti supponendo $m \leq n$ (altrimenti si sostituisce A con A^H) possiamo partizionare Σ e blocchi nel seguente modo

$$\Sigma = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix} \begin{matrix} k \text{ righe} \\ m-k \text{ righe} \\ k \text{ colonne} \quad m-k \text{ colonne} \end{matrix}$$

e partizionare le matrici U e V^H nel seguente modo

$$U = [\underbrace{u_1, \dots, u_k}_{k \text{ colonne}} | \underbrace{u_{k+1}, \dots, u_m}_{m-k \text{ colonne}}] = [U_k | \tilde{U}_{m-k}^H]$$

$$V = [\underbrace{v_1, \dots, v_k}_{k \text{ colonne}} | \underbrace{v_{k+1}, \dots, v_m}_{m-k \text{ colonne}}] = [V_k | \tilde{V}_{m-k}^H]$$

dalla def. di SVD risulta

$$A = U \Sigma V^H = U_k \Sigma_k V_k^H$$

2) $\text{Null}(A) = \{x \in \mathbb{R}^m \mid Ax=0\} \equiv \text{span}\{v_{k+1}, v_{k+2}, \dots, v_m\}$

Sia $x \in \mathbb{R}^m$ e' $Ax=0 \Leftrightarrow U \Sigma V^H x = 0 \Leftrightarrow \Sigma V^H x = 0$

indichiamo con $z = \Sigma V^H x$ questo vettore si può partizionare nel seguente modo $z \in \mathbb{C}^{m \times 1}$

$$z = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_k^H \\ \tilde{V}_{m-k}^H \end{bmatrix} x \in \mathbb{C}^{m \times 1}$$

$$= \begin{bmatrix} \Sigma_k V_k^H x \\ 0 \end{bmatrix} \begin{matrix} k \text{ componenti} \\ m-k \text{ componenti} \end{matrix}$$

quindi $\Sigma V^H x = 0 \Rightarrow \Sigma_k V_k^H x = 0 \Rightarrow V_k^H x = 0$

\Rightarrow quest'ultima relazione ci dice che x è ortogonale alle prime k colonne di V (perché V è unitario)

\Rightarrow poiché V è unitario $\Rightarrow x$ deve essere generato (comb. lineare) dalle restanti colonne di $V \Rightarrow x \in \text{span}\{v_{k+1}, \dots, v_m\}$

3) $R(A) = \{y \in \mathbb{R}^m \mid Ax = y\} = \text{span}\{\mu_1, \mu_2, \dots, \mu_k\}$

Sia $y = Ax = U \Sigma V^H x = U_k \sum_k V_k^H x = U_k z$

$\Rightarrow y = z_1 \mu_1 + \dots + z_k \mu_k \Rightarrow y \in \text{span}\{\mu_1, \dots, \mu_k\}$

4) $\text{rank}(A) = k$ (poiché $\text{rank}(A) = \dim R(A)$)

5) σ_i^2 sono gli autovalori di $(A^H A)$ ($\sigma_i^2 \in \sigma(A^H A)$)

consideriamo $A^H A = (U \Sigma V^H)^H (U \Sigma V^H) = V \Sigma^H U^H U \Sigma V^H = V \Sigma_k^2 V^H$

$A^H A$ è simile a Σ_k^2 mediante la trasformazione unitaria V

$\Rightarrow \sigma(A^H A) = \sigma(\Sigma_k^2) = \{\sigma_1^2, \sigma_2^2, \dots, \sigma_k^2, \dots, 0\}$

6) $\|A\|_F^2 = \text{tr}(A^H A) = \sum_{i=1}^k \sigma_i^2$ (ricordarsi di traccia e $\rho(A)$ di matrici simili coincidono)

$\|A\|_2^2 = \rho(A^H A) = \sigma_1^2 \Rightarrow \|A\|_2 = \sigma_1$

(ricordarsi i concetti di norme $\| \cdot \|_F$ e $\| \cdot \|_2$)

$\|A\|_F^2 = \sum_{i,j} |a_{ij}|^2 = \sum_i \|A_{i*}\|_2^2 = \sum_j \|A_{*j}\|_2^2 = \text{tr}(A^H A)$

Teor. TSVD (Truncated SVD)

$A \in \mathbb{C}^{m \times n}$ $\text{rank}(A) = k$ $r \in \mathbb{N}$ $[r < k]$

$A_r = \sum_{i=1}^r \sigma_i u_i v_i^H$ è la matrice "più vicina" ad A in $\| \cdot \|_2$ cioè

$\min \|A - B\|_2 = \|A - A_r\|_2 = \sigma_{r+1}$

$\text{rank}(B) = r$
 $B \in \mathbb{C}^{m \times n}$

($r+1$ -esimo valore singolare)

$$A \in \mathbb{R}^{m \times n}$$

$$\text{rank}(A) = r$$

①

$$\exists U \in \mathbb{R}^{m \times m}$$

$$\exists V \in \mathbb{R}^{n \times n}$$

$$A = U \Sigma V^T$$

$$\Sigma = \begin{pmatrix} \sigma_1 & & & 0 \\ & \ddots & & \\ & & \sigma_r & \\ 0 & & & 0 \end{pmatrix} \quad \text{ortogonali } U, V$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$$

i valori singolari σ_i^2 sono gli autovalori di $A^T A$
ed i vettori singolari sono particolari autovettori di $A^T A$
Un algoritmo per il calcolo delle SVD è dato dal
metodo QR applicato ad $A^T A$ (senza calcolo diretto del
prodotto $A^T A$)

INTERPRETAZIONE GEOMETRICA

I valori singolari $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n$ di una matrice forniscono
informazioni sulla quantità di distorsione che si ha utilizzando
la trasformazione lineare definita dalla matrice A

Possiamo vedere ciò analizzando come A distorce una sfera

Supponiamo $A \in \mathbb{R}^{m \times n}$ non singolare e sia
la sfera in \mathbb{R}^n (sfera unitaria)

$$S_2 = \{x \mid \|x\|_2 = 1\}$$

vettori di norma 1

La natura dell'immagine $A(S_2)$ si può ottenere considerando
la SVD di A

A è invertibile?

$$A = U \Sigma V^T \Rightarrow A^{-1} = V \Sigma^{-1} U^T$$

$$y \in A(S_2) \Rightarrow \exists x \in \mathbb{R}^n \quad \|x\|_2 = 1 \quad \text{e} \quad Ax = y$$

$$\begin{aligned} 1 = \|x\|_2^2 &= \|A^{-1} Ax\|_2^2 = \|V \Sigma^{-1} U^T y\|_2^2 = \\ &= \|\Sigma^{-1} U^T y\|_2^2 = \|\Sigma^{-1} w\|_2^2 = \\ &= \frac{w_1^2}{\sigma_1^2} + \frac{w_2^2}{\sigma_2^2} + \dots + \frac{w_r^2}{\sigma_r^2} \end{aligned}$$

$U^T A(S_2)$ è l'ellissoide il cui k -esimo semiasse ha
lunghezza σ_k . Poiché U^T è una matrice ortogonale
quindi conserva la lunghezza.

U^T influisce solo sull'orientazione di $A(S_2)$ (2)

$\Rightarrow A(S_2)$ è un ellissoide il cui k -esimo semiasse è σ_k



Il grado di distorsione di una sfera unitaria sotto la trasformazione lineare A è misurato da

$$k_2 = \frac{\sigma_1}{\sigma_n}$$

il rapporto tra il più grande ed il più piccolo valore singolare

Inoltre il più lungo ed il più corto vettore dell'ellissoide $A(S_2)$ hanno rispettivamente lunghezze

$$\begin{aligned} \max_{\|x\|_2=1} \|Ax\|_2 &= \|A\|_2 = \|U\Sigma V^T\|_2 = \|\Sigma\|_2 = \sigma_1 \\ \min_{\|x\|_2=1} \|Ax\|_2 &= \frac{1}{\|A^{-1}\|_2} = \frac{1}{\|V\Sigma^{-1}V^T\|_2} = \frac{1}{\|\Sigma^{-1}\|_2} = \frac{1}{\sigma_n} \end{aligned}$$

$$k_2 = \frac{\sigma_1}{\sigma_n}$$

è chiamato numero di condizione in norma 2

Se $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ sono i valori singolari di A ($m \times n$) allora per ogni $K < r$ la distanza da A alla matrice di rango K più vicina ad A è data da

$$\sigma_{K+1} = \min_{\text{rank}(B)=K} \|A - B\|_2$$

Filtraggio di dati

La SVD può essere utilizzata ^{nelle} applicazioni per effettuare un ordinamento di dati rumorosi ed estrarre informazioni rilevanti.

Supponiamo che A ($m \times n$) sia una matrice contenente dei dati contaminati da un certo livello di rumore.

La SVD permette di riscrivere A in r componenti mutuamente ortogonali

$$A = U \begin{pmatrix} \sigma_1 & \dots & \sigma_r & 0 \\ & & & 0 \\ 0 & & & 0 \end{pmatrix} V^T = \sum_{i=1}^r \sigma_i u_i v_i^T = \sum_{i=1}^r \sigma_i Z_i$$

$Z_i = u_i v_i^T$ e $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ (che è la stessa dimensione di A)

Le matrici (Z_1, Z_2, \dots, Z_r) costituiscono un insieme di matrici ortonormali perché (cambiando la norma di Frobenius come prodotto scalare)

$$\text{tracce}(Z_i^T Z_j) = \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases}$$

$\sigma_i = \text{tracce}(Z_i^T A)$ può essere interpretato come la porzione di A che gioca nella "direzione" di Z_i

In molte applicazioni il rumore che contamina i dati contenuti in A è random (non direzionale) nel senso che il rumore è distribuito più o meno uniformemente lungo ogni Z_i

Conseguentemente ogni termine $\sigma_i z_i$ contiene approssimativamente lo stesso livello di rumore.

Questo significa che indicando con

(4)

$SNR(\sigma_i z_i)$ il signal-to-noise-ratio in $\sigma_i z_i$
si ha (si può definire il rapporto tra segnale-rumore come il reciproco del coefficiente di variazione ovvero il rapporto tra la media e la dev. standard del segnale o di una sua misurazione)

$$SNR(\sigma_1 z_1) \geq SNR(\sigma_2 z_2) \geq \dots \geq SNR(\sigma_r z_r)$$

Se i valori singolari $\sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r$ sono piccoli relativamente a

$$\frac{(\text{rumore totale})}{r}$$

allora i termini $\sigma_{k+1} z_{k+1}, \dots, \sigma_r z_r$ hanno un piccolo SNR.

Quindi eliminando alcuni termini $A = \sum_{i=1}^r \sigma_i z_i$ sebbene perdiamo una piccola parte del segnale complessivo rimuoviamo una parte ampia delle componenti del rumore totale in A .

Questo spiega perché la TSVD $A_k = \sum_{i=1}^k \sigma_i z_i$ può in molti casi filtrare il rumore in A senza una perdita "significativa" di informazioni.

Per determinare il migliore valore di k di solito si applicano delle procedure empiriche che variano da applicazioni ad applicazioni.

Un meccanismo ~~all~~ iniziale per scegliere k potrebbe anche essere basato sull'osservazione del gap tra il più grande ed il più piccolo valore singolare.

Come calcolare la f. decomposizione SVD di A

Supponiamo $m \geq n$ (se fosse $m < n$ basta riferirsi alla matrice A^H)

- 1) Si calcolano gli autovalori e gli autovettori normalizzati in $\| \cdot \|_2$ di $A^H A$ e si costruisce la seguente decomp. in forma di Shur di $A^H A$

$$A^H A = Q^H D Q^H \quad D \in \mathbb{R}^{n \times n} \quad Q \in \mathbb{C}^{n \times n}$$

D matrice degli autovalori in ordine non crescente di $A^H A$ e Q è la matrice degli autovettori

- 2) Si calcola la matrice

$$C = A Q \in \mathbb{C}^{m \times n}$$

- 3) Si calcola la fattorizzazione QR di C utilizzando la tecnica del pivoting per ottenere una matrice triang. sup. con elementi principali non negativi ed ordinati in modo non crescente

$$C \Pi = U R = U \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$$

$$R_1 \in \mathbb{C}^{n \times n}$$

Π matrice di permutazione
(R_1)_{ii} ≥ 0

$$A = C Q^H = C \Pi \Pi^H Q^H = U R \Pi^T Q^H$$

$$\Rightarrow A^H A = Q \Pi R^T U^H U R \Pi^T Q^H = Q \Pi R^T R \Pi^T Q^H$$

P.S.

$$\Rightarrow A^H A = Q \pi R^H R \pi^T Q^H = Q \pi R_1^H R_1 \pi^T Q^H$$

da $A^H A = Q^H D Q$ otteniamo

$$Q^H D Q = Q \pi R_1^H R_1 \pi^T Q^H$$

$$D = \pi R_1^H R_1 \pi^T$$

$$\Rightarrow R_1^H R_1 = \underbrace{\pi^T D \pi}_{\text{diagonale}}$$

$$\Rightarrow R_1^H R_1 \text{ \u00e9 diagonale} \Rightarrow R_1 \text{ \u00e9 diagonale}$$

Si pone $\Sigma = R$ e $V = Q \pi$

e si ottiene la SVD di A .

Gufetti

$$A = U R \pi^T Q^H \equiv U \Sigma V^H$$

SVD Troncata (TSVD)

La SVD consente di risolvere il seguente problema di minimo

$$\text{rank}(A) = k$$

Dato $A \in \mathbb{C}^{m \times n}$ \forall ed $r \in \mathbb{N}$ $r < k$

determinare la matrice $B \in \mathbb{C}^{m \times n}$ $\text{rank}(B) = r$

$$\text{min} \|A - B\|_2$$

p\u00f9 "vicina" ad A

Prop.

$$A \in \mathbb{C}^{m \times n}$$

$$\text{rank}(A) = k$$

$$A = U \Sigma V^H$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k > \sigma_{k+1} = \sigma_{k+2} = \dots = \sigma_p = 0$$

$$\min_{\substack{B \in \mathbb{C}^{m \times n} \\ \text{rank}(B) = k}} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1}$$

$$\text{con } A_k = \sum_{j=1}^k \sigma_j u_j v_j^H$$

Applicazione ~~de~~ SVD al problema dei minimi quadrati

Consideriamo il sist. lineare

$$Ax = b$$

$$A \in \mathbb{C}^{m \times n}$$

$$m \geq n$$

più righe che colonne

Se il sist. non ha soluzione fissata una norma vettoriale $\|\cdot\|$ si cercano i vettori $x \in \mathbb{C}^n$ s.t.

$$\min_x \|Ax - b\|_2$$

Questo problema si chiama "problema ai minimi quadrati"

A tale sist. come la soluz. minima si può calcolare utilizzando il sistema delle eq. normali

$$A^H A x = A^H b$$

vediamo come è possibile calcolare la soluzione del problema ai minimi quadrati utilizzando la fatt. SVD

Sia $A \in \mathbb{C}^{m \times n}$ con $\text{rank}(A) = k$. Consideriamo

$$A = U \Sigma V^H$$

$$U \in \mathbb{C}^{m \times m}$$

$$V \in \mathbb{C}^{n \times n}$$

$$\Sigma \in \mathbb{R}^{m \times m}$$

$$\Sigma = (\sigma_1 \dots \sigma_k \dots 0)$$

$$\|Ax - b\|_2^2 = \|U^H(Ax - b)\|_2^2 = \|U^H A V V^H x - U^H b\|_2^2$$

$\| \cdot \|_2$ inv. x trasf. ortog.

$$y = V^H x$$

$$= \|U^H A V y - U^H b\|_2^2$$

dalla SVD

$$= \|\Sigma y - U^H b\|_2^2$$

$$y = V^H x \in \mathbb{C}^n$$

$$U = [u_1 \dots u_m]$$

Osserviamo che

$$\Sigma y = \begin{bmatrix} \sigma_1 y_1 \\ \sigma_2 y_2 \\ \vdots \\ \sigma_k y_k \\ 0 \\ \vdots \\ 0 \end{bmatrix}_{m \times 1}$$

$$U^H b = \begin{bmatrix} u_1^H b \\ u_2^H b \\ \vdots \\ u_m^H b \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

$$\|U^H b\|_2^2 = \sum_{i=1}^m |u_i^H b|^2 = \sum_{i=1}^k |u_i^H b|^2 + \sum_{i=k+1}^m |u_i^H b|^2$$

$$= \sum_{i=1}^k |u_i^H b|^2 + \sum_{i=k+1}^m |u_i^H b|^2$$

$$\Sigma y - U^H b = \begin{bmatrix} \sigma_1 y_1 - u_1^H b \\ \vdots \\ \sigma_k y_k - u_k^H b \\ -u_{k+1}^H b \\ \vdots \\ -u_m^H b \end{bmatrix}_{m \times 1}$$

$$\|\Sigma y - U^H b\|_2^2 = \sum_{i=1}^k |\sigma_i y_i - u_i^H b|^2 + \sum_{i=k+1}^m |u_i^H b|^2$$

Il minimo dell'espressione precedente si è raggiunto quando il primo addendo è nullo

$$\sigma_i y_i - u_i^H b = 0$$

$$y_i = \frac{u_i^H b}{\sigma_i} \quad i=1, \dots, k$$

$$y_i = 0 \quad i=k+1, \dots, m$$

Il settore di minime norme

$$y^* = \begin{cases} \frac{u_i^H b}{\delta_i} & i = 1, \dots, k \\ 0 & i = k+1, \dots, m \end{cases}$$

$$y = V^H x$$

$x = Vy$ e $\|x\|_2 = \|y\|_2$ la sol. del prob. di min 2

$$x^* = Vy^* = \sum_{i=1}^k y_i^* v_i = \sum_{i=1}^k \frac{u_i^H b}{\delta_i} v_i$$

ed

$$\|Ax^* - b\|_2^2 = \sum_{i=k+1}^m |u_i^H b|^2$$

Decomposizione e valori singolari di $A \in \mathbb{C}^{m \times n}$

$$U = [u_1 \dots u_m] \quad V = [v_1 \dots v_n]$$

$$A \in \mathbb{R}^{m \times n}$$

$$\exists U \in \mathbb{R}^{m \times m}$$

$$\exists V \in \mathbb{R}^{n \times n}$$

U, V ortogonali

Σ $m \times n$ diagonale sup e blocchi

$$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \\ 0 & & \end{bmatrix}$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$$

$$r = \text{rank}(A)$$

$$r \leq \min(m, n)$$

tale che

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix}$$

$$D = \text{diag}[\sigma_1, \dots, \sigma_r]$$

$$A = U \Sigma V^T$$

gli elementi di Σ si chiamano valori singolari di A

i settori u_i settori singolari sinistri

" v_i " " destri

U, V non sono uniche mentre Σ è unico

$$A = \sum_{k=1}^r \sigma_k u_k v_k^T$$

$$AA^T = U \Sigma V^T V \Sigma U^T = U \Sigma \Sigma^T U^T \rightarrow \text{autovalori } AA^T$$

~~$$A^T A = V (\Sigma^T \Sigma) V^T$$~~

$$A^T A = V (\Sigma^T \Sigma) V^T$$

$$\|A\|_2 = \sqrt{\rho(A^T A)}$$

\rightarrow autovalori di $A^T A$

σ_i di A sono legati agli autovalori della matrice

$$A^T A \longleftrightarrow \sigma_i = \sqrt{\lambda_i(AA^T)}$$

DEF. di Pseudoinversa

$$A \in \mathbb{C}^{m \times n}$$

$$r = \text{rang}(A)$$

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix} \begin{matrix} r \times r & r \times (n-r) \\ (m-r) \times r & (m-r) \times (n-r) \end{matrix}$$

$$A = U \Sigma V^T$$

$$D = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$

$$\Sigma^+ = \begin{bmatrix} D^{-1} & 0 \\ 0 & 0 \end{bmatrix}$$

$$D^{-1} = \begin{bmatrix} 1/\sigma_1 & & \\ & \ddots & \\ & & 1/\sigma_r \end{bmatrix}$$

$$\Sigma \Sigma^+ \Sigma = \Sigma \Rightarrow \Sigma^T (\Sigma^+)^T \Sigma^+ = \Sigma^T$$

$$\Sigma^+ \Sigma \Sigma^+ = \Sigma^+$$

$$(\Sigma^+ \Sigma)^T = \Sigma^+ \Sigma$$

$$(\Sigma \Sigma^+)^T = \Sigma \Sigma^+$$

Si dice inversa generalizzata di A o
inversa di Moore-Penrose

$$A^+ = V \Sigma^+ U^T$$

$$\begin{aligned} 1) \quad A A^+ A &= U \Sigma V^T V \Sigma^+ U^T U \Sigma V^T \\ &= U \Sigma \Sigma^+ \Sigma V = U \Sigma^+ V = A \end{aligned}$$

$$2) \quad A^+ A A^+ = A^+$$

$$3) \quad (A A^+)^T = A A^+$$

$$4) \quad (A^+ A)^T = A^+ A$$

$$\rightarrow A^T A A^+ = A^T$$

se $\text{rang}(A) = n < m$

$$A^+ = (A^T A)^{-1} A^T$$

$$\text{rang}(A) = n = m$$

$$A^+ = A^{-1}$$